

Estacionamentos Inteligentes (*Smart Parking*)

Utilizando técnicas de aprendizagem profunda

Pedro Ivo Aragão Guimarães

Departamento de engenharia elétrica - DEE
Universidade Federal de Campina Grande - UFCG

Trabalho de Conclusão de Curso.
Orientador : Dr. Rafael Bezerra Correia Lima.

16 de outubro de 2021



Visão geral.

1. Motivação e proposta.
2. Breve conceitos.
3. Metodologia.
4. Projeto e resultados.
5. Considerações finais.
6. Referências.



Seção.

1. Motivação e proposta.
2. Breve conceitos.
3. Metodologia.
4. Projeto e resultados.
5. Considerações finais.
6. Referências.



Motivação.

- Entre os anos de 2008 e 2018, houve um número crescente de automóveis no país, que passou de 37,1 milhões para 65,7 milhões [Azevedo e Ribeiro 2019].
- 30% do congestionamento do tráfego é causado por buscas de locais para estacionar, que duram cerca de 7 a 8 minutos por tentativa [Arnott e Inci 2006].



Motivação.

- Entre os anos de 2008 e 2018, houve um número crescente de automóveis no país, que passou de 37,1 milhões para 65,7 milhões [Azevedo e Ribeiro 2019].
- 30% do congestionamento do tráfego é causado por buscas de locais para estacionar, que duram cerca de 7 a 8 minutos por tentativa [Arnott e Inci 2006].

Problemas causados

Falta de mobilidade urbana, estresse no trânsito, maior consumo de combustível e consequente aumento da poluição do ar.



Proposta para solução.

- A inteligência artificial (IA) vem buscando métodos para solucionar este problema, isto só se tornou possível nos dias atuais pela disponibilidade de grandes recursos de dados e a melhoria na capacidade de processamento dos computadores.



Proposta para solução.

- A inteligência artificial (IA) vem buscando métodos para solucionar este problema, isto só se tornou possível nos dias atuais pela disponibilidade de grandes recursos de dados e a melhoria na capacidade de processamento dos computadores.

Examples

Sistemas de visão computacional podem ser úteis através do fornecimento de informações em tempo real aos motoristas sobre a disponibilidade e a localização das vagas de um estacionamento, reduzindo o tempo gasto para encontrar as vagas.



Proposta para solução.

- A inteligência artificial (IA) vem buscando métodos para solucionar este problema, isto só se tornou possível nos dias atuais pela disponibilidade de grandes recursos de dados e a melhoria na capacidade de processamento dos computadores.

Examples

Sistemas de visão computacional podem ser úteis através do fornecimento de informações em tempo real aos motoristas sobre a disponibilidade e a localização das vagas de um estacionamento, reduzindo o tempo gasto para encontrar as vagas.

Objetivo proposto

Oferecer um modelo classificador para vagas de estacionamentos, com técnicas de aprendizagem profunda, para auxiliar a mobilidade urbana das cidades inteligentes.



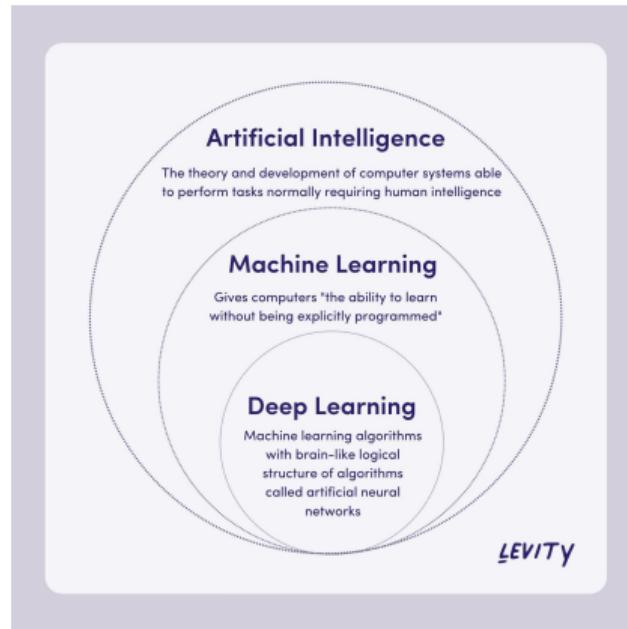
Seção.

1. Motivação e proposta.
2. Breve conceitos.
3. Metodologia.
4. Projeto e resultados.
5. Considerações finais.
6. Referências.



Campo de atuação.

Figura 1: Campos da IA.



Levity



Redes Neurais (RNA).

- As Redes neurais artificiais (RNA) é um algoritmo de IA.
- As RNA são inspiradas no comportamento do cérebro humano (neurônios e sinapses).
- A semelhança vem de utilizar elementos simples (neurônios) para compor um sistema mais complexo, por meio das ligações das sinapses.



Redes Neurais (RNA).

- As Redes neurais artificiais (RNA) é um algoritmo de IA.
- As RNA são inspiradas no comportamento do cérebro humano (neurônios e sinapses).
- A semelhança vem de utilizar elementos simples (neurônios) para compor um sistema mais complexo, por meio das ligações das sinapses.

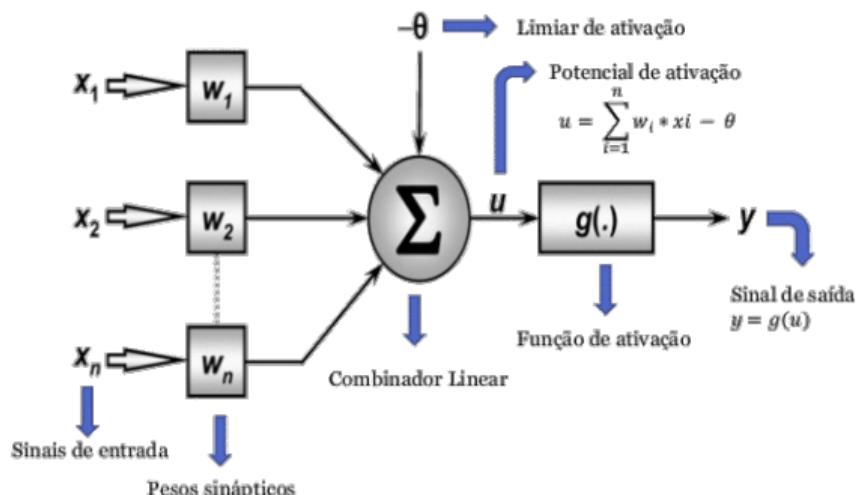
Redes Artificiais

A partir da composição de funções lineares simples ligadas em rede, modelar sistemas complexos.



Exemplo de rede neural.

Figura 2: Exemplo de RNA de uma camada.

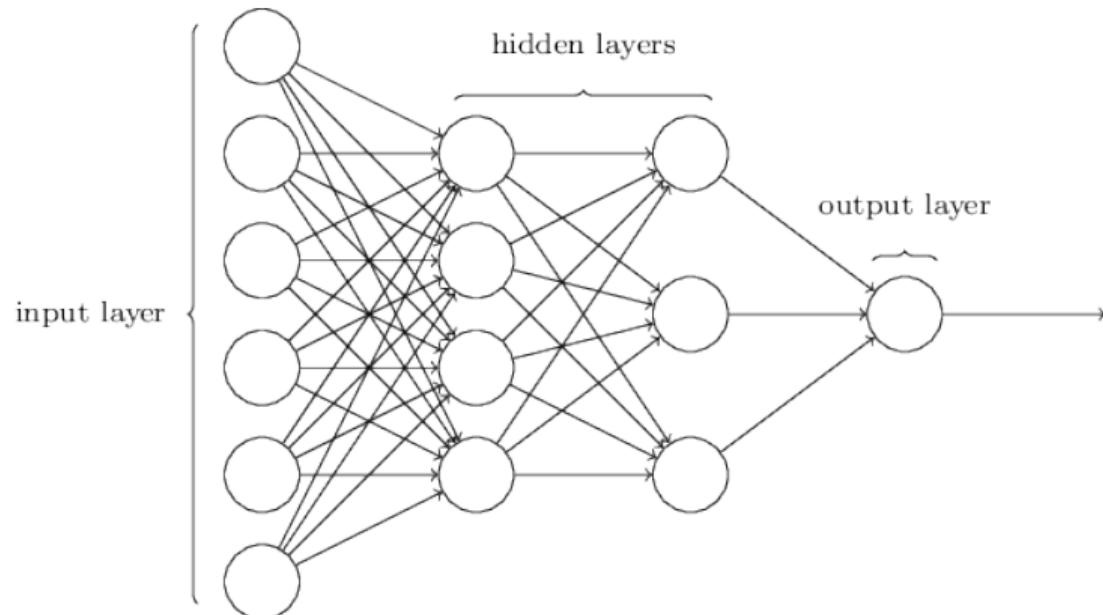


[Palmiere 2016]



Perceptron de Multicamadas (MLP).

Figura 3: MLP.



[Elipe 2020]



Gradiente descendente, Propagação e Retropropagação.

Gradiente descendente (∇)

Aponta a direção que a função deve seguir para minimizar a função de custo (erro).

Propagação (*feedforward (FF)*) \Rightarrow

Multiplicação dos pesos e composições de funções por meio da função de ativação.

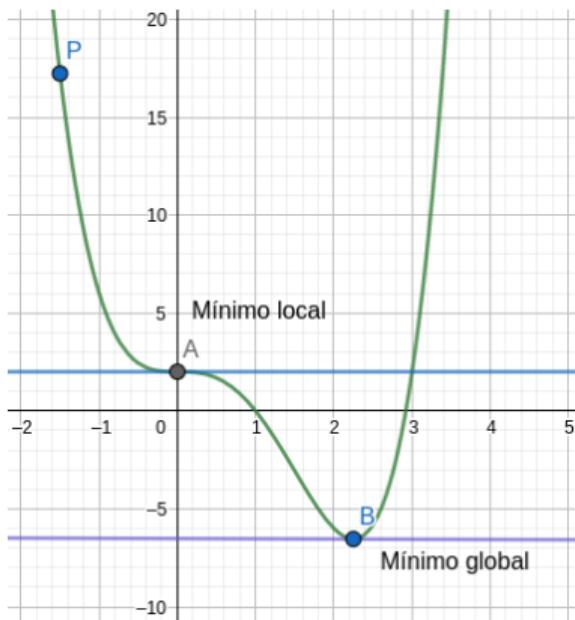
Retropopagação (*backpropagation (BP)*) \Leftarrow

Estimar o erro e a direção do gradiente para cada peso aplicando derivadas parciais e regra da cadeia para decompor as funções.



Mínimo local e mínimo global.

Figura 4: Função de custo.



Guimarães (2021)



Redes neurais convolucionais (Convnet / CNN).

- Algoritmo de *deep learning* para trabalhar com visão computacional.
- Uma arquitetura tradicional MLP, cada pixel seria uma entrada na RNA (inviável).



Redes neurais convolucionais (Convnet / CNN).

- Algoritmo de *deep learning* para trabalhar com visão computacional.
- Uma arquitetura tradicional MLP, cada pixel seria uma entrada na RNA (inviável).

Camadas Convolucionais

Convolução com um filtro para extrair os pixels mais significantes da imagem e formar mapas de características com as informações relevantes.



Redes neurais convolucionais (Convnet / CNN).

- Algoritmo de *deep learning* para trabalhar com visão computacional.
- Uma arquitetura tradicional MLP, cada pixel seria uma entrada na RNA (inviável).

Camadas Convolucionais

Convolução com um filtro para extrair os pixels mais significantes da imagem e formar mapas de características com as informações relevantes.

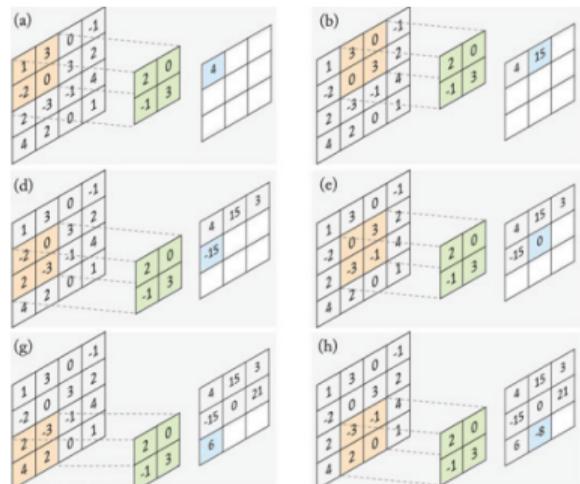
Camadas de amostragem (*pooling*)

Recebe o mapa de característica e condensa por meio de amostragem (*downsampling*).



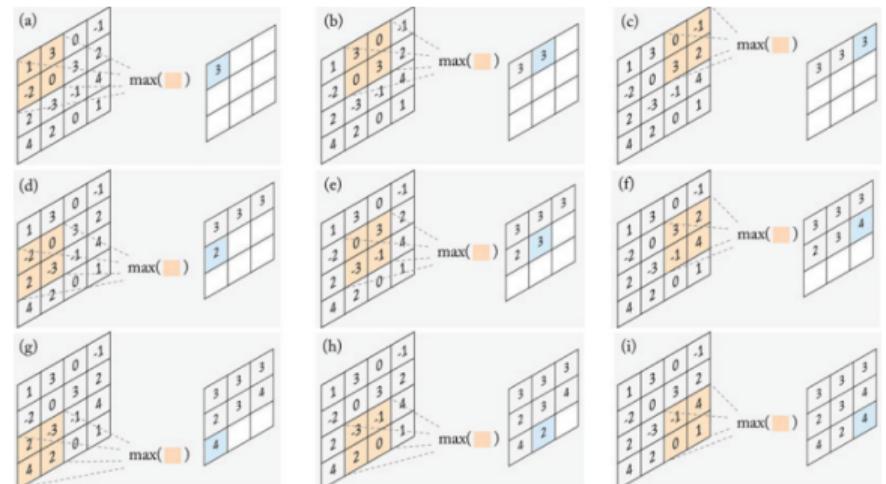
Exemplos de Convolução e Máx pooling.

Figura 5: Convolução.



[Khan et al. 2018]

Figura 6: Máx Pooling.



[Khan et al. 2018]



Seção.

1. Motivação e proposta.
2. Breve conceitos.
3. Metodologia.
4. Projeto e resultados.
5. Considerações finais.
6. Referências.



Ciclo de um projeto de aprendizagem profunda.

Um projeto de aprendizagem de máquinas é um processo cíclico até a otimização e que atenda os requisitos planejados. Em sua fase de projeto segue as seguintes etapas:

1. Coleta de dados.
2. Pré-processamento das imagens.
3. Escolha do modelo e definição da arquitetura.
4. Treinar o modelo.
5. Avaliar os resultados em bases de validação e teste.
6. Ajustar os parâmetros.



Coleta de dados.

- A coleta de dados é uma das fases mais importantes em um projeto de aprendizagem profunda e um dos grandes responsáveis pelo crescimento deste algoritmo nos últimos anos.
- "Comparado com o aprendizado de máquina tradicional, o aprendizado profundo é mais adequado para o processamento de *big data*, pois o desempenho do algoritmo melhora com o aumento do volume de dados" [Goodfellow, Bengio e Courville 2016].



dataset Pklot.

- Contém 12.417 imagens dos estacionamentos e 695.899 ROI'S de vagas que foram manualmente checadas e rotuladas.
- Todas as imagens foram retiradas de estacionamentos da Universidade Federal do Paraná (UFPR) e da Pontifícia Universidade Católica do Paraná (PUCPR), localizadas em Curitiba.
- O *dataset* é composto por três base dados diferentes: PUCPR, UFPR04 e UFPR05.



Tabela 1: Resumo do *dataset* PKLOT

LOCAL	Condições	Dias	Img.	Ocupada	Vazia	Total
UFPR04	ENSOLARADO	20	2098	32166 (54.98%)	26334 (45.02%)	58400
	NUBLADO	15	1408	11608 (29.47%)	27779 (70.53%)	39387
	CHUVOSO	14	285	2351 (29.54%)	5607 (70.46%)	7958
	TOTAL	49	3791	46125 (43.58%)	59720 (56.42%)	105845
UFPR05	ENSOLARADO	25	2500	57584 (57.65%)	42306 (42.35%)	99890
	NUBLADO	19	1426	33764 (59.27%)	23202 (40.73%)	56966
	CHUVOSO	8	226	6078 (68.07%)	2851 (31.93%)	8929
	TOTAL	52	4152	97426 (58.77%)	68359 (41.23%)	165785
PUCPR	ENSOLARADO	24	2315	96762 (46.42%)	101672 (53.58%)	208433
	NUBLADO	11	1328	42363 (31.90%)	90417 (68.10%)	132780
	CHUVOSO	8	831	55104 (66.35%)	27951 (33.65%)	83056
	TOTAL	43	4474	194229 (45.78%)	230040 (51.46%)	424269



Figura 7: PKlot.



[de Almeida et al. 2015]



Segmentação das regiões de interesses (ROI's)

Figura 8: demarcando ROIs.

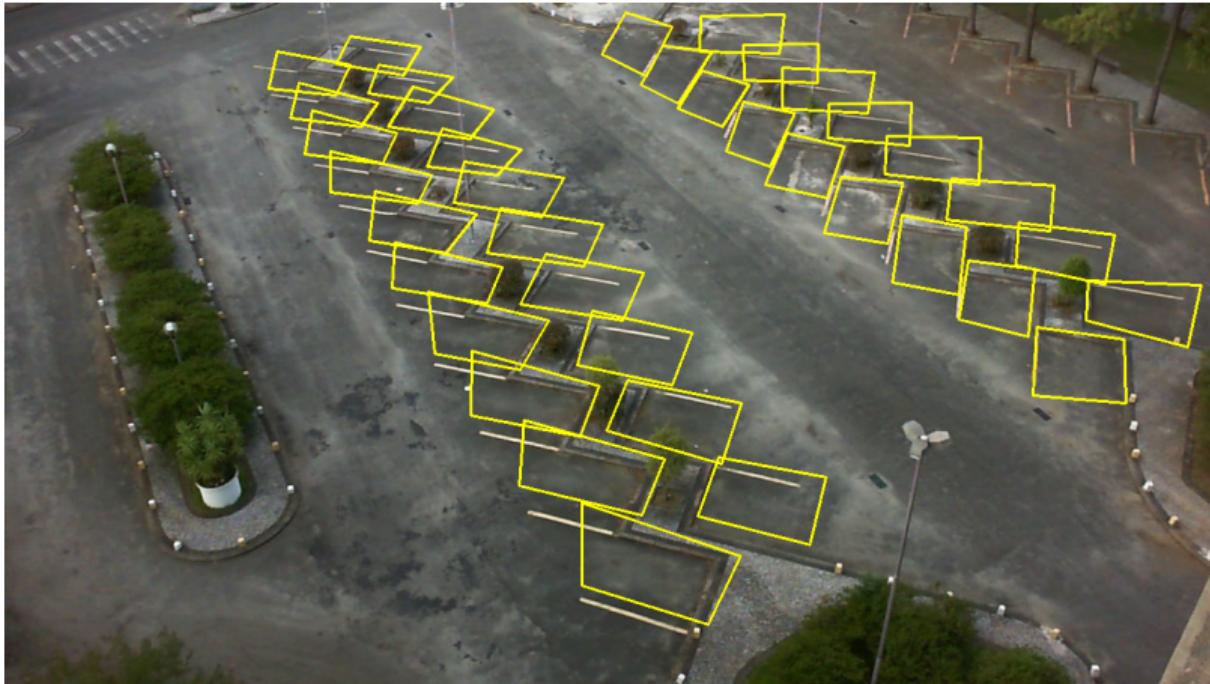


Figura 9: Segmentação.

Tabela 2: Tabela das ROI'S

LOCAL	Qtd. imagens	Vagas Ocupada	Vagas Vazia	Total
UFPR04	3791	5336	5248	58400
UFPR05	4152	16292	11388	27680
PUCPR	4474	21598	33302	54900

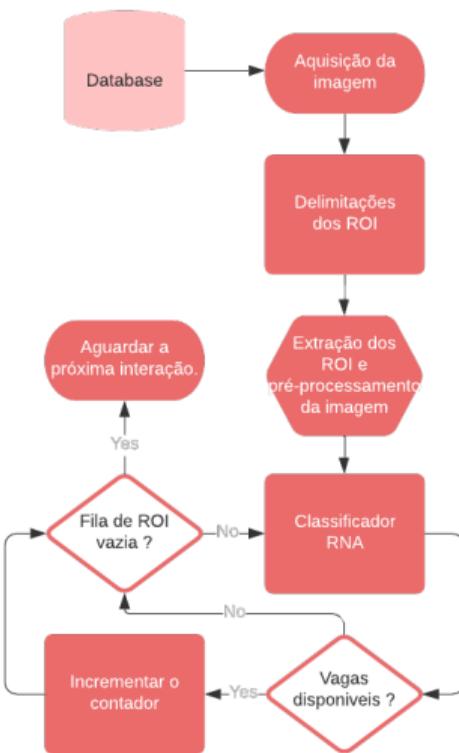


Seção.

1. Motivação e proposta.
2. Breve conceitos.
3. Metodologia.
4. Projeto e resultados.
5. Considerações finais.
6. Referências.



Figura 10: Fluxograma.



Arquitetura do modelo.

Figura 11: Arquitetura do modelo.

Layer (type)	Output Shape	Param #
<hr/>		
input_2 (InputLayer)	[(None, 160, 160, 3)]	0
rescaling_1 (Rescaling)	(None, 160, 160, 3)	0
mobilenetv2_1.00_160 (Function)	(None, 5, 5, 1280)	2257984
global_average_pooling2d (GlobalAveragePooling2D)	(None, 1280)	0
dropout (Dropout)	(None, 1280)	0
dense (Dense)	(None, 1)	1281
<hr/>		
Total params: 2,259,265		
Trainable params: 1,281		
Non-trainable params: 2,257,984		



Hiper parâmetros.

- Número de camadas densas = 1.
- $\textit{Dropout} = 20\%$.
- Função de ativação - sigmoide.
- Função de perda - *BinaryCrossentropy* (Utilizada para problemas de classificação).
- Taxa de aprendizado = 10^{-4} .
- Número de épocas = 10.
- Tamanho do lote (*batch size*) = 32.



Treinamento - UFPR04.

Tabela 3: Resumo do treinamento UFPR04.

UFPR04 - 28 vagas	Precisão	Perda
Avaliação na base de treino	0,9902	0,0388
Avaliação na base de validação	0,9907	0,0410
Avaliação na base de teste	0,9918	0,0441
Épocas	10	
Lote	32	
Taxa de aprendizado	0,0001	
<i>Dropout</i>	20%	
Otimizador	Adam	
Função de Perda	<i>BinaryCrossentropy</i>	
Métricas	Precisão	



Figura 12: Precisão e perda - UFPR04.

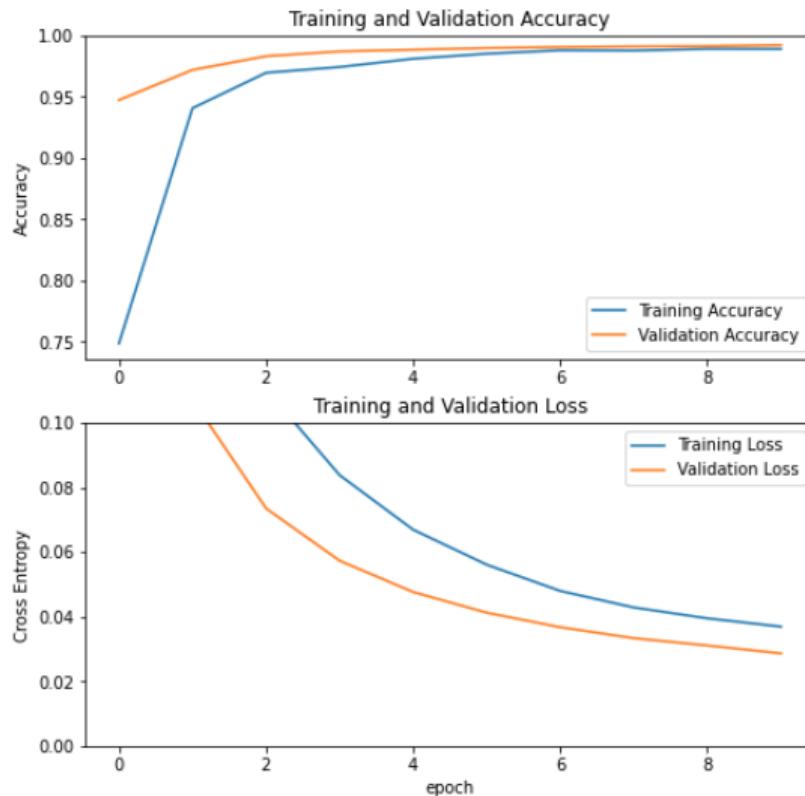


Figura 13: Predição nas ROIs - UFPR04.



Treinamento - UFPR05.

Tabela 4: Resumo do treinamento UFPR05.

UFPR05 - 37 vagas	Precisão	Perda
Avaliação na base de treino	0,9922	0,0287
Avaliação na base de validação	0,9923	0,0286
Avaliação na base de teste	0,9920	0,0285
Épocas	10	
Lote	32	
Taxa de aprendizado	0,0001	
<i>Dropout</i>	20%	
Otimizador	Adam	
Função de Perda	<i>BinaryCrossentropy</i>	
Métricas	Precisão	



Figura 14: Precisão e perda - UFPR05.

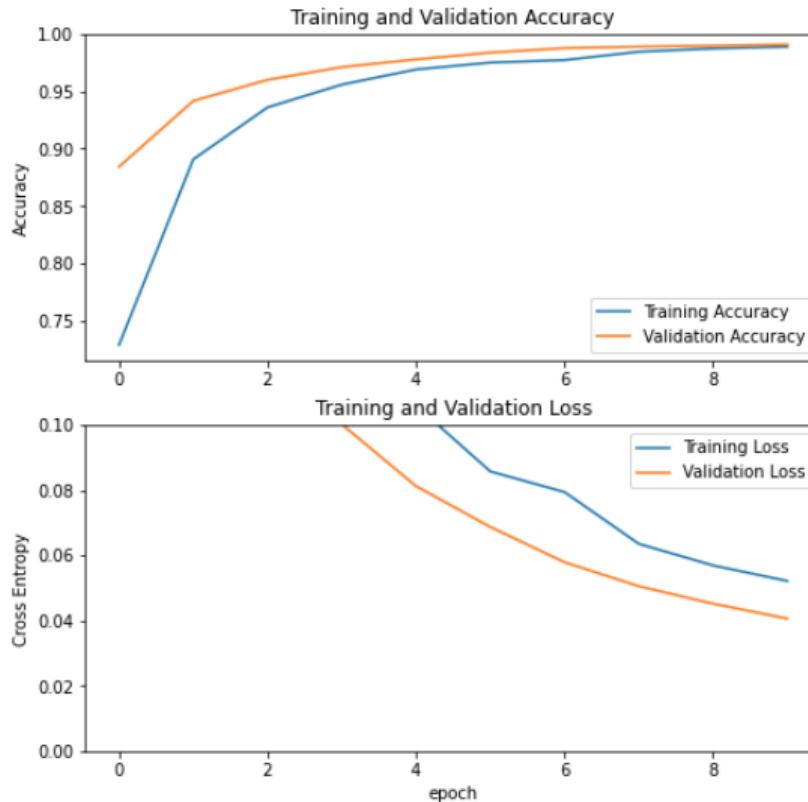


Figura 15: Predição nas ROIs - UFPR05.



Treinamento - PUCPR.

Tabela 5: Resumo do treinamento PUCPR.

PUCPR - 100 vagas	Precisão	Perda
Avaliação na base de treino	0,9313	0,1976
Avaliação na base de validação	0,9267	0,2069
Avaliação na base de teste	0,9267	0,2061
Épocas	10	
Lote	32	
Taxa de aprendizado	0,0001	
<i>Dropout</i>	20%	
Otimizador	Adam	
Função de Perda	<i>BinaryCrossentropy</i>	
Métricas	Precisão	



Figura 16: Precisão e perda - PUCPR.

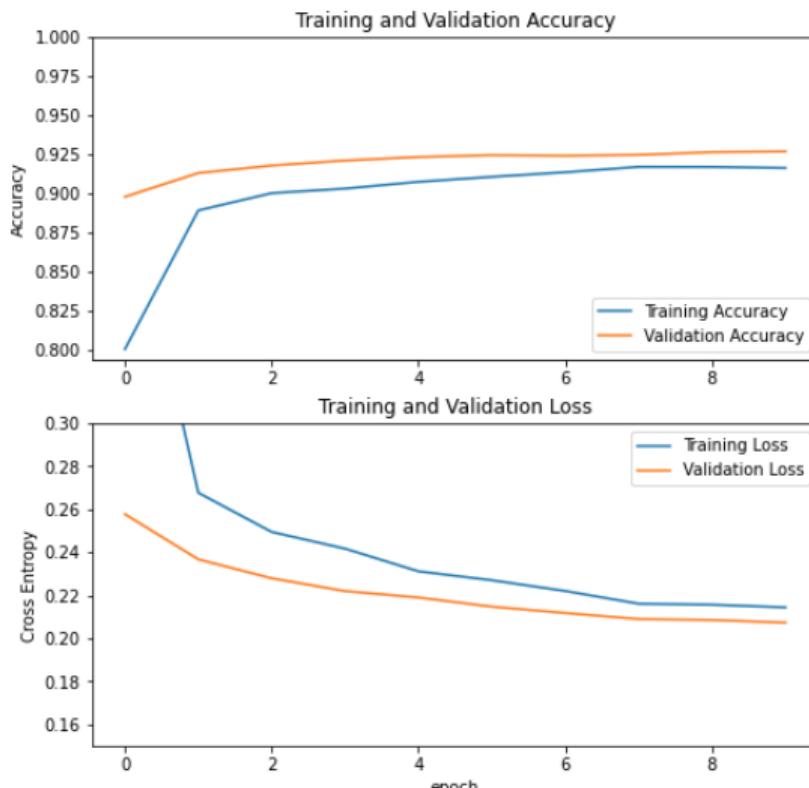
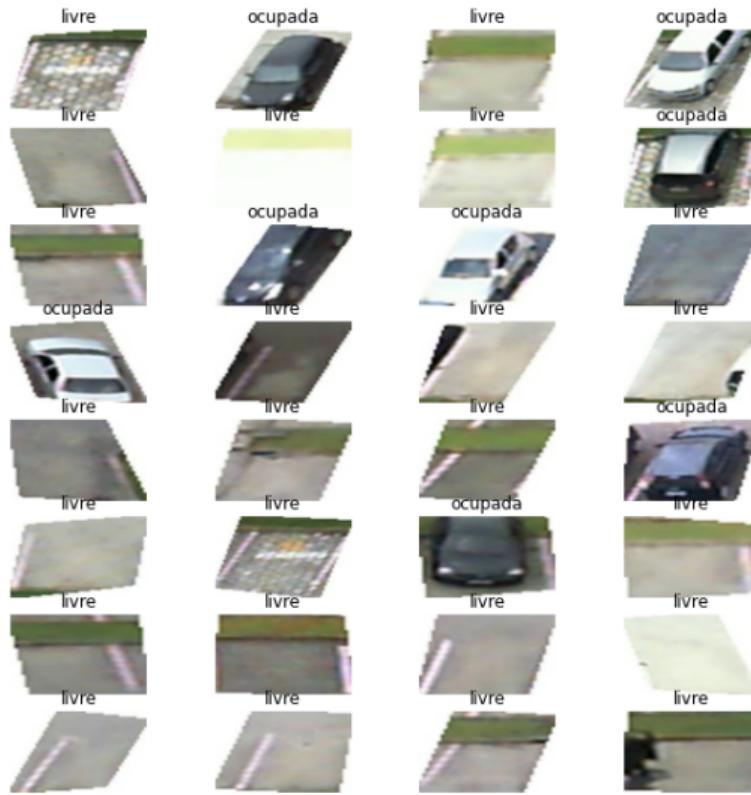


Figura 17: Predição nas ROIs - PUCPR.

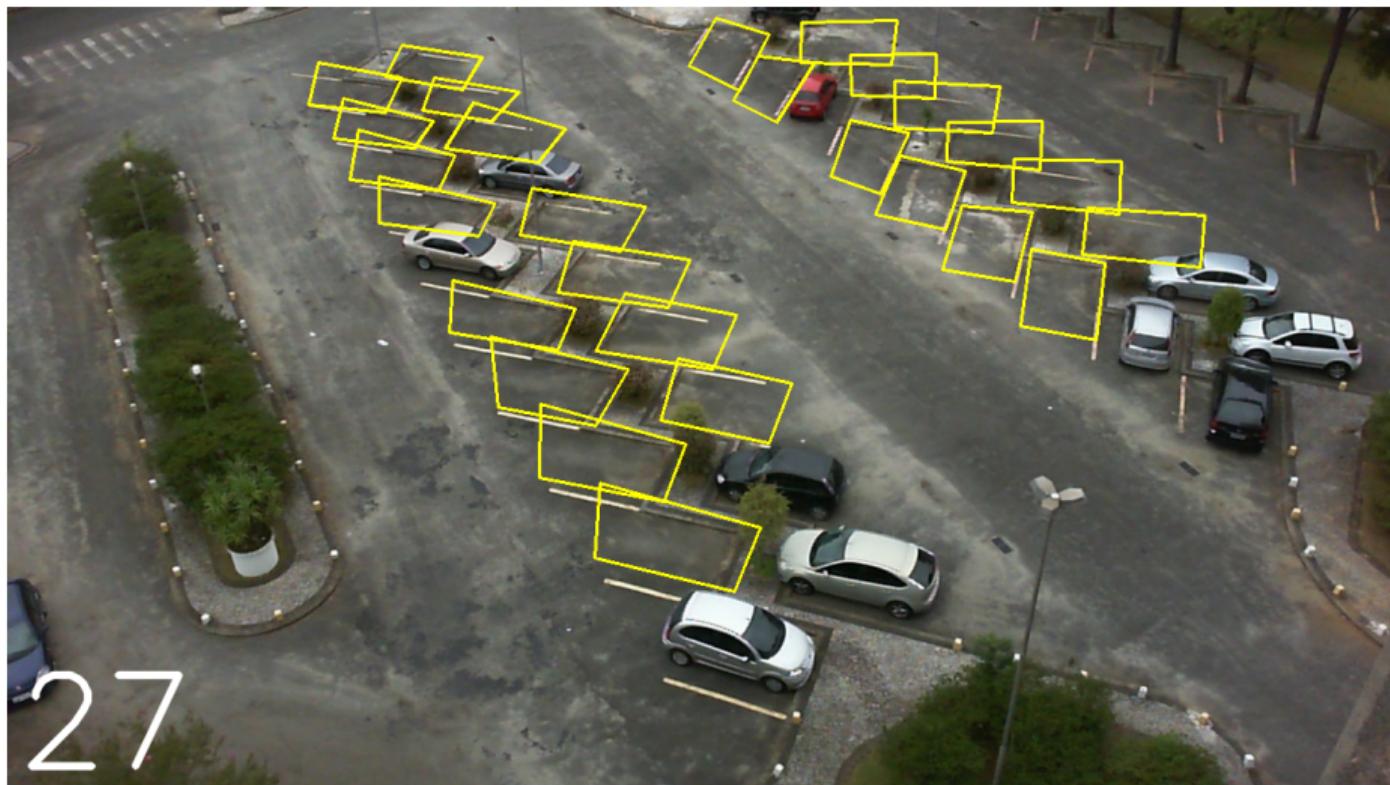


Predição das vagas no sistema.

- Carregar imagens aleatórias do estacionamento completo na base de dados do UFPR05.
- Predição em tempo real das 37 vagas.

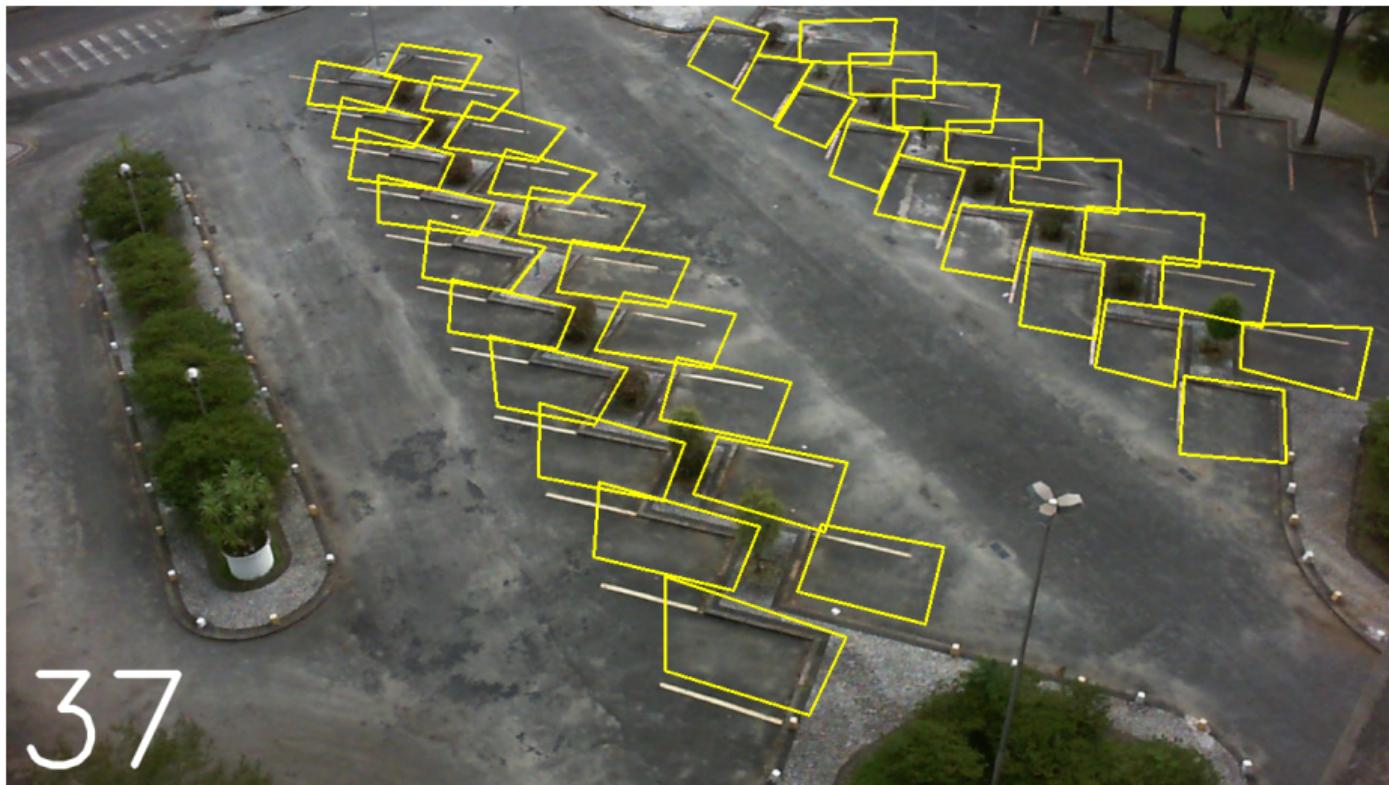


Figura 18: Predição do sistema.



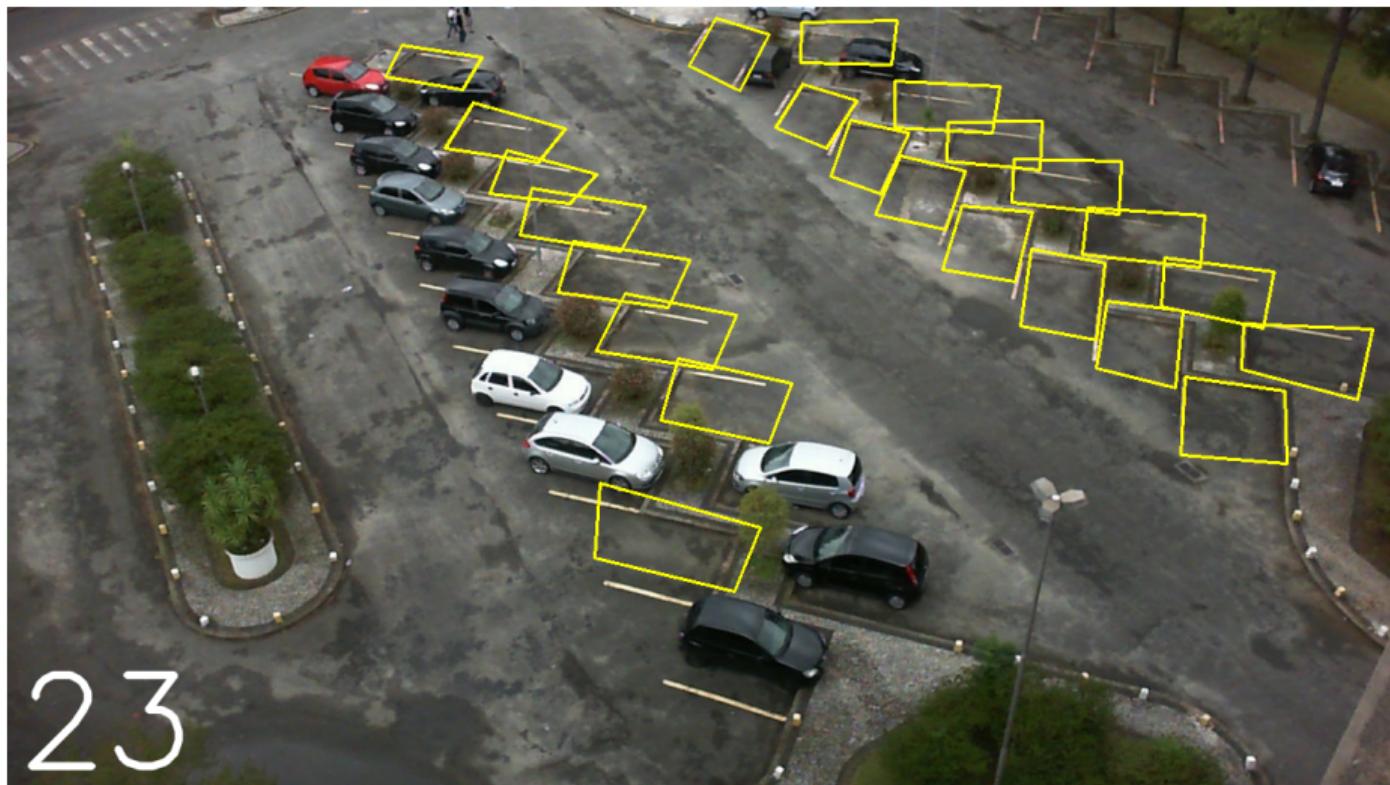
27

Figura 19: Predição do sistema.



37

Figura 20: Predição do sistema.



23

Seção.

1. Motivação e proposta.
2. Breve conceitos.
3. Metodologia.
4. Projeto e resultados.
5. Considerações finais.
6. Referências.



Avaliação dos resultados.

Os resultados do projeto do classificador foram satisfatórios, equiparado a literatura atual em resultados e em metodologia.

A predição das 37 vagas (UFPR05) ocorre com baixa latência (2,3s), com precisão alta. A metodologia aplicada é compatível com as pesquisas atuais na área

TRABALHOS FUTUROS:

- Validar os resultados em novas bases e extrair novas métricas.
- Adicionar as etapas de implementações e monitoramento.
- Sintonizar os hiper parâmetros do modelo.
- Criar interface móvel para o público alvo.
- Publicar artigos para disseminar o conhecimento científico obtido.



Obrigado!¹

¹Todo o material de código-fonte deste projeto está disponível neste link no github em um repositório público com o passo a passo para a reprodução.



Seção.

1. Motivação e proposta.
2. Breve conceitos.
3. Metodologia.
4. Projeto e resultados.
5. Considerações finais.
6. Referências.



-  ARNOTT, R.; INCI, E. An integrated model of downtown parking and traffic congestion. *Urban Economics*, v. 60, n. 3, p. 418–442, 2006.
-  AZEVEDO, S.; RIBEIRO, L. *Mapa da motorização individual no Brasil*. 2019. Disponível em: <https://www.observatoriodasmetropoles.net.br/wp-content/uploads/2019/09/mapa_moto2019v2.pdf>. Acesso em: 28 de julho de 2021.
-  de Almeida, P. R. et al. Pklot – a robust dataset for parking lot classification. *Expert Systems with Applications*, v. 42, n. 11, p. 4937–4949, 2015. ISSN 0957-4174. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S0957417415001086>>.
-  ELIPE, D. R. *Rede Perceptron de uma única camada*. 2020. Disponível em: <<https://github.com/d-r-e/multilayer-perceptron>>. Acesso em: 05 de outubro de 2021.
-  GOODFELLOW, I.; BENGIO, Y.; COURVILLE, A. *Deep Learning*. [S.I.]: MIT Press, 2016. <http://www.deeplearningbook.org>.
-  KHAN, S. et al. *A Guide to Convolutional Neural Networks for Computer Vision*. [S.I.: s.n.], 2018.



 PALMIERE, S. E. *Rede Perceptron de uma única camada.* 2016. Disponível em:
<<https://www.embarcados.com.br/rede-perceptron-de-uma-unica-camada/>>. Acesso em:
02 de outubro de 2021.

